SPRAWOZDANIE

Zajęcia: Matematyka konkretna

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium Nr 01 Data 14-03-2026 Temat: "Metoda SVD w celu obliczenia korelacji" Wariant 7	Łukasz Pezda Informatyka II stopień, niestacjonarne, 2 semestr

1. Cel sprawozdania

Celem jest nabycie podstawowej znajomości użycia rozkładu SVD w celu rozwiązywania problemów powiązanych z użyciem korelacji.

Zadanie dotyczy obliczenia korelacji obrazu zgodnie z wariantem pod względem zarówno wierszy jak i kolumn z użyciem SVD. Przedstawić macierzy korelacji graficznie.

Celem zadania było praktyczne zastosowanie rozkładu według wartości osobliwych (SVD) do analizy korelacji wewnątrz obrazu cyfrowego. Zgodnie z poleceniem, należało wyznaczyć i zaprezentować graficznie dwie macierze korelacji dla wczytanego obrazu: względem wierszy oraz względem kolumn. Wykorzystanie SVD miało na celu optymalizację i zaprezentowanie alternatywnego, stabilnego numerycznie sposobu obliczania macierzy kowariancji/korelacji.

2. Opis programu opracowanego

Wczytano niezbędne biblioteki oraz przygotowano dane wejściowe. Obraz docelowy został wczytany i zredukowany do skali szarości, co jest wymagane do przeprowadzenia dwuwymiarowej analizy SVD. Dodatkowo obraz przeskalowano do rozdzielczości 100x100 pikseli. Zabieg ten pozwala na znaczne przyspieszenie obliczeń oraz sprawia, że docelowe macierze korelacji będą czytelne podczas prezentacji graficznej.

```
import numpy as np
import matplotlib.pyplot as plt
from skimage import io, color, transform

img_raw = io.imread('7.webp')

if img_raw.ndim >= 3:
    img = color.rgb2gray(img_raw[..., :3])
else:
    img = img_raw

img = transform.resize(img, (100, 100))
```

Obliczenie korelacji wierszy. Aby wynik SVD odpowiadał klasycznej macierzy korelacji, obraz został najpierw ustandaryzowany: odjęto średnią dla każdego wiersza i podzielono przez odchylenie standardowe oraz czynnik skalujący.

Klasyczna korelacja wierszy jest proporcjonalna do iloczynu $X*X^T$. Zamiast bezpośrednio mnożyć macierze, wykorzystano rozkład SVD:

$X = U\Sigma V^T$.

Zgodnie z własnościami algebry liniowej:

$X*X^T = (U\Sigma V^T)(V\Sigma U^T) = U\Sigma^2 U^T$

W kodzie macierz U oraz Σ zostały wyznaczone za pomocą funkcji np.linalg.svd, a następnie przemnożone zgodnie z powyższym wzorem, tworząc macierz korelacji wierszy corr_rows.

```
img_row_centered = img - np.mean(img, axis=1, keepdims=True)
img_row_std = np.std(img_row_centered, axis=1, keepdims=True)
img_row_std[img_row_std == 0] = 1
img_row_norm = img_row_centered / (img_row_std * np.sqrt(img.shape[1] - 1))

U_r, S_r, Vt_r = np.linalg.svd(img_row_norm, full_matrices=False)
corr_rows = U_r @ np.diag(S_r**2) @ U_r.T
```

Druga część polecenia wymagała wyznaczenia korelacji względem kolumn. Proces przygotowania danych jest analogiczny, jednak standaryzacja odbywa się wzdłuż osi kolumn.

Macierz korelacji kolumn jest proporcjonalna do iloczynu X^T*X. Po zastosowaniu rozkładu SVD otrzymujemy zależność wykorzystującą macierz V^T:

$X^T*X = (V\Sigma U^T)(U\Sigma V^T) = V\Sigma^2 V^T$

Wynik obliczeń, zgodny z powyższym wzorem matematycznym, został przypisany do zmiennej corr_cols. Zastosowanie parametru full_matrices=False w funkcji SVD zoptymalizowało pamięciowo cały proces.

```
img_col_centered = img - np.mean(img, axis=0, keepdims=True)
img_col_std = np.std(img_col_centered, axis=0, keepdims=True)
img_col_std[img_col_std == 0] = 1
img_col_norm = img_col_centered / (img_col_std * np.sqrt(img.shape[0] - 1))

U_c, S_c, Vt_c = np.linalg.svd(img_col_norm, full_matrices=False)
corr_cols = Vt_c.T @ np.diag(S_c**2) @ Vt_c
```

Ostatnim etapem, zgodnie z poleceniem, było graficzne przedstawienie wyznaczonych macierzy. Wykorzystano do tego bibliotekę matplotlib. Wyniki zaprezentowano w formie map ciepła, stosując paletę kolorów coolwarm. Pozwala ona na łatwą interpretację wizualną:

- Kolor czerwony oznacza silną korelację dodatnią.
- Kolor niebieski oznacza silną korelację ujemną.
- Kolory jasne/białe wskazują na brak korelacji.

Główna przekątna obu macierzy korelacji jest idealnie czerwona, co potwierdza poprawność obliczeń – każdy wiersz/kolumna w 100% koreluje sam ze sobą.

```
fig, axes = plt.subplots(1, 3, figsize=(16, 5))

axes[0].imshow(img, cmap='gray')
axes[0].set_title('Oryginalny obraz (7.webp, skompresowany)')
axes[0].axis('off')

im1 = axes[1].imshow(corr_rows, cmap='coolwarm', vmin=-1, vmax=1)
axes[1].set_title('Macierz korelacji wierszy (SVD)')
fig.colorbar(im1, ax=axes[1], fraction=0.046, pad=0.04)

im2 = axes[2].imshow(corr_cols, cmap='coolwarm', vmin=-1, vmax=1)
axes[2].set_title('Macierz korelacji kolumn (SVD)')
fig.colorbar(im2, ax=axes[2], fraction=0.046, pad=0.04)

plt.tight_layout()
plt.show()
```

Na podstawie otrzymanych wyników można dokonać precyzyjnej oceny struktury wczytanego obrazu.

Macierz korelacji wierszy:

Na wykresie środkowym doskonale widoczna jest główna przekątna o maksymalnej wartości korelacji, co jest zjawiskiem naturalnym, każdy wiersz jest w pełni skorelowany sam ze sobą.

Oprócz tego na wykresie można zaobserwować wyraźne, równoległe do przekątnej pasma o podwyższonej korelacji dodatniej oraz ujemnej. Taki układ świadczy o silnej okresowości wzoru w kierunku pionowym. Elementy na zdjęciu powtarzają się w regularnych odstępach wierszy.

Macierz korelacji kolumn

Wykres po prawej stronie również wykazuje silną główną przekątną. Widoczne na nim wzory tworzą szersze, regularne bloki/prążki rozchodzące się na boki. Wskazuje to na obecność powtarzalnych struktur w kierunku poziomym.

Rozkład ten jest jednak nieco inny niż w przypadku wierszy, co wynika bezpośrednio z geometrii ułożenia obiektów na zdjęciu oryginalnym.

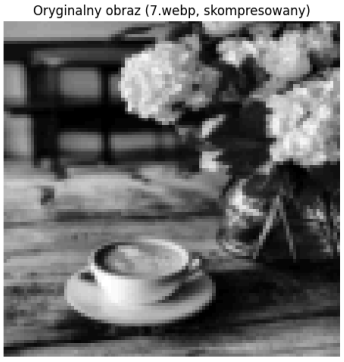

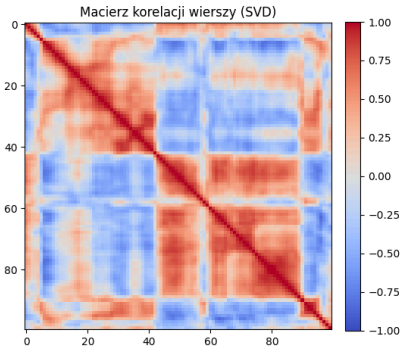

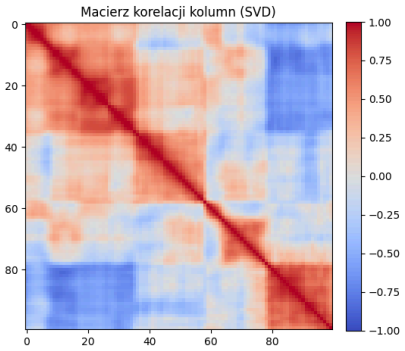

3. Wnioski

Zastosowanie rozkładu SVD do wyznaczenia macierzy korelacji okazało się niezwykle skuteczną metodą detekcji i wizualizacji cech strukturalnych obrazu.

Obie mapy ciepła bezbłędnie uwypukliły geometryczną i periodyczną naturę badanej grafiki, wyodrębniając ukryte zależności między poszczególnymi wierszami i kolumnami pikseli bez konieczności skomplikowanej analizy w dziedzinie częstotliwości.